

Kto odpowiada ankieterowi?

Diagnoza nieignorowalnego braku odpowiedzi za pomocą randomizowanego instrumentu odpowiedzi — przewodnik po pilotażu FRBN

Ben Stanley (Uniwersytet SWPS, Centrum Studiów nad Demokracją)

21 września 2026

Spis treści

1 Problem, który próbujemy rozwiązać	1
1.1 Sondaże słyszą dziś niemal nikogo	1
1.2 Kiedy założenie zawodzi	2
1.3 Dlaczego niskie odsetki odpowiedzi są groźne, a nie tylko niechlujne	2
2 Rozwiązanie Bailey'a: zaprojektować badanie tak, by obciążenie zostawiło ślad	2
2.1 Kolejka	2
2.2 Od diagnozy do naprawy	3
3 Demonstracja: syntetyczna Polska	3
3.1 Świat syntetyczny	3
3.2 Jak wygląda selekcja na cenie nieobserwowanej	3
4 Projekt badania: randomizacja protokołu kontaktu	4
5 Krok 1: czy instrument działa?	5
6 Krok 2: test diagnostyczny	5
7 Krok 3: ważenie nie ratuje pytań oznaczonych jako podejrzane	6
8 Krok 4: modele selekcji z instrumentem	7
9 Odczytanie wyników: drzewo decyzyjne	8
10 Co to oznacza dla polaryzacji	9
11 Od demonstracji do pilotażu FRBN	10
11.1 Co faktycznie zrealizujemy	10
11.2 Co rzeczywiste badanie ma, a czego symulacja nie miała	10
11.3 Główne ryzyka i to, co je amortyzuje	11
11.4 Co z tego powstanie	11
11.5 Po co to wszystko, w jednym akapicie	12
12 Bibliografia	12

Tekst przygotowany dla współpracowniczek i współpracowników z Centrum Studiów nad Demokracją oraz zespołu PGSW. Wyjaśnia, czemu służy pilotaż FRBN (decyzja nr 67/2026/FRBN/C) i dlaczego został zaprojektowany właśnie tak, posługując się demonstracją na danych syntetycznych, w której prawidłowa odpowiedź jest znana. Wszystkie liczby i wykresy pochodzą z tej symulacji, a nie z rzeczywistych danych polskich: pokazują, co metoda potrafi, a nie co ustaliliśmy. Zespół projektu: Ben Stanley (kierownik), Mikołaj Cześniak, Marta Żerkowska-Balas.

1 Problem, który próbujemy rozwiązać

1.1 Sondaże słyszą dziś niemal nikogo

Prawie wszystko, co twierdzimy na temat polskiej opinii publicznej — przewidywana frekwencja, poparcie partii, postawy wobec mniejszości, przywiązanie do norm demokratycznych — powstaje na podstawie badań, w których zdecydowana większość zaproszonych nigdy nie odpowiada. W typowym polskim badaniu internetowym (CAWI) ankietę wypełnia mniej niż co dziesiąta zaproszona osoba. Wszystko, o czym informujemy, pochodzi od mniejszości, która *zechciała* wziąć udział.

Standardową naprawą jest **ważenie**: próbę koryguje się tak, by jej struktura odpowiadała populacji pod względem wieku, płci, wykształcenia i miejsca zamieszkania. Raking, poststratyfikacja i kalibracja to warianty tego samego posu-

nięcia. Zabieg ten działa i jest niezbędny — opiera się jednak na założeniu, które rzadko formułuje się równie wprost, jak na to zasługuje:

Respondent jest wymienialny z tymi osobami, które nie odpowiedziały, a mają ten sam profil demograficzny. Gdy tylko cechy demograficzne się zgadzają, ci, którzy odpowiedzieli, mówią nam to, co powiedzieliby ci, którzy tego nie zrobili.

Dla wielu pytań jest to z grubsza prawda. Dla niektórych — i to często akurat tych, na których najbardziej zależy politologom — nie jest.

1.2 Kiedy założenie zawodzi

Sklonność do wypełnienia ankiety politycznej nie rozkłada się losowo. Osoby zaangażowane politycznie lubią sondaże polityczne i częściej chodzą na wybory. Osoby nieufne wobec instytucji albo przekonane, że ich poglądy są źle widziane, po cichu znikają z próby — i mają odrębne opinie. W takich przypadkach *sama treść odpowiedzi wiąże się ze skłonnością do jej udzielenia*.

To właśnie **nieignorowalny brak odpowiedzi**: skłonność do odpowiedzi R^* jest skorelowana ze zmienną wynikową Y przy kontroli wszystkiego, co obserwujemy. Ważenie demograficzne nie jest w stanie ani tego wykryć, ani naprawić, ponieważ osoby brakujące różnią się *opiniami*, a nie tylko wiekiem czy wykształceniem. Korektę stosujemy wzdłuż wymiarów, które widzimy; szkoda powstaje wzdłuż wymiaru, którego nie widzimy.

1.3 Dlaczego niskie odsetki odpowiedzi są groźne, a nie tylko niechlujne

Pożyteczny rachunek (Meng 2018; Bailey 2024, rozdz. 5) rozkłada błąd średniej sondażowej przy losowym kontakcie na trzy czynniki:

$$\text{błąd} = \underbrace{\rho}_{\text{korelacja selekcja-odpowiedź}} \times \underbrace{\sqrt{\frac{1-p_r}{p_r}}}_{\text{kara za odsetek odpowiedzi}} \times \underbrace{\sigma_Y}_{\text{zmiennosc odpowiedzi}}$$

Zmienił się człon środkowy. Przy 50-procentowym odsetku odpowiedzi wynosi 1. Przy 10 procentach — 3. Przy 5 procentach — 4,4. Korelacja między udziałem w badaniu a treścią odpowiedzi, która w 1980 roku byłaby błędem zaokrąglenia, dziś daje obciążenie rzędu kilkunastu punktów. Co kluczowe, **liczebność próby tu nie pomaga**: kara zależy od *odsetka* odpowiedzi, a nie od liczby zrealizowanych wywiadów. Większa obciążona próba to próba, która myli się z większą pewnością siebie.

Wynikają stąd dwie konsekwencje, które porządkują cały projekt:

1. To, czy $\rho \neq 0$, jest **pytaniem empirycznym, rozstrzyganym osobno dla każdego pytania**. Nie jest to własność badania, panelu ani techniki; jest to własność każdego pojedynczego pytania. Frekwencja może być mocno skażona, podczas gdy poparcie dla członkostwa w UE pozostaje czyste.
2. Ponieważ ρ dotyczy nieobserwowanych nierespondentów, nie da się go w ogóle oszacować na podstawie zwykłego sondażu. Trzeba go **przewidzieć w projekcie badania**.

2 Rozwiązanie Baileya: zaprojektować badanie tak, by obciążenie zostawiło ślad

Projekt wdraża ramy teoretyczne z książki Michaela Baileya *Polling at a Crossroads* (Cambridge University Press, 2024), zwłaszcza z rozdziałów 8–12.

2.1 Kolejka

Wyobraźmy sobie wszystkie zaproszone osoby ustawione w kolejce według chęci udziału w badaniu. Sondaż o niskim wskaźniku odpowiedzi słyszy wyłącznie początek kolejki. Sondaż, który naciska mocniej — przypomnienia, zachęty, dłuższy okres realizacji — sięga głębiej i zbiera także osoby mniej chętne.

Zrealizujmy więc to samo badanie na dwa sposoby jednocześnie. Losowo przydzielmy połowę zaproszonych do **protokołu lekkiego kontaktu** (jedno zaproszenie, potem cisza), a połowę do **protokołu intensywnego** (zaproszenie i przypomnienia). Ramię lekkie obejmuje wyłącznie chętny początek kolejki. Ramię standardowe obejmuje chętnych oraz wycinek niechętnych. Porównajmy ich odpowiedzi, pytanie po pytaniu:

- **Takie same odpowiedzi w obu ramionach** → niechętni przypominają chętnych, co przemawia za tym, że niedostępni przypominają jednych i drugich. Brak odpowiedzi jest dla tego pytania ignorowalny, a zwykle ważenie — wiarygodne.

- **Różne odpowiedzi** → skłonność do udziału wiąże się z treścią odpowiedzi. Publikowana wartość jest przesunięta, a ważenie jej nie uratuje.

Ponieważ przydział do ramienia jest rzutem monetą, różnicy między ramionami nie da się przypisać temu, że od początku byli to ludzie innego rodzaju. To właśnie czyni z takiego bodźca **randomizowany instrument odpowiedzi**: losowo przydzielone oddziaływanie, które zmienia to, czy ktoś odpowiada, nie zmieniając tego, *co myśli*.

Formalnie instrument Z musi spełniać dwa warunki:

- **Warunek włączenia** (*inclusion*): Z zmienia prawdopodobieństwo udzielenia odpowiedzi, i to wyraźnie. Słaby instrument sprawia, że cała dalsza analiza jest bezużyteczna.
- **Warunek wyłączenia** (*exclusion restriction*): Z nie wpływa na odpowiedzi tych, którzy wzięli udział. Randomizacja gwarantuje to w wartości oczekiwanej; co robimy, by chronić ten warunek w praktyce, opisuje dalsza część poświęcona projektowi badania.

2.2 Od diagnozy do naprawy

Gdy już widzimy, jak zmieniają się odpowiedzi w miarę sięgania głębiej w kolejkę, modele selekcji (Heckman 1979 i jego kontynuacje) potrafią ekstrapolować tę zmianę na osoby, które nigdy nie odpowiadały, i wyprodukować skorygowane oszacowania. Bailey dowodzi, że zła reputacja tych modeli nie bierze się z błędnej matematyki, lecz z tego, że rutynowo karmiono je danymi pozbawionymi instrumentu — identyfikacja opierała się wtedy wyłącznie na postaci funkcyjnej. Jeśli dostarczyć im prawdziwy randomizowany instrument, zachowują się porządnie.

3 Demonstracja: syntetyczna Polska

Wszystko, co znajduje się w rozdziałach 4–8, pochodzi z symulacji, a to z jednego powodu: w symulacji znamy prawdę. Możemy więc sprawdzić nie tylko to, czy diagnostyka się uruchamia, ale i to, czy skorygowane oszacowania trafiają tam, gdzie powinny.

3.1 Świat syntetyczny

Tworzymy populację 100 000 osób dorosłych o realistycznej strukturze demograficznej (płeć, wiek, wykształcenie, wielkość miejscowości). Dwie **nieobserwowane** cechy wpływają następnie zarówno na udział w badaniu, jak i na część odpowiedzi:

- **zaangażowanie polityczne** — podnosi prawdopodobieństwo odpowiedzi; podnosi deklarowaną frekwencję oraz postawy przychylne mniejszościom i demokracji;
- **zaufanie do instytucji** — podnosi prawdopodobieństwo odpowiedzi; obniża poparcie dla stygmatyzowanej partii antyestablishmentowej.

Konstruujemy sześć pytań: cztery są z założenia skażone, dwa są czyste:

Pytanie	Zależne od cech ukrytych?	Zakładany werdykt
Pewny udział w wyborach	zaangażowanie ↑	nieignorowalny — zawyżany w sondażach
Stygmatyzowana partia	zaufanie ↓	nieignorowalny — zaniżany
Indeks postaw wobec mniejszości	zaangażowanie + zaufanie ↑	nieignorowalny — zawyżany
Normy demokratyczne	zaangażowanie + zaufanie ↑	nieignorowalny — zawyżany
Poparcie dla członkostwa w UE	wyłącznie demografia	ignorowalny — ważenie działa
Palenie papierosów	wyłącznie demografia	ignorowalny — ważenie działa


Pytania w świecie syntetycznym. Dwa pytania kontrolne to uczciwa połowa ćwiczenia: diagnostyka, która uruchamia się przy wszystkim, nie jest diagnostyką.

Następnie zapraszamy do badania 30 000 losowo wybranych osób i dzielimy listę zaproszeń losowo, w proporcji 50/50, na dwa protokoły kontaktu.

3.2 Jak wygląda selekcja na cesze nieobserwowanej

Rysunek 1 pokazuje to, czego normalnie zobaczyć nie możemy. Każdy punkt to jedna zaproszona osoba. Oś pozioma to jej (ukryta) skłonność do odpowiedzi, oś pionowa — odpowiedź na indeksie postaw wobec mniejszości. Czerwone

punkty odpowiadały, szare nie. W rzeczywistym badaniu punkty szare są niewidoczne — obserwujemy wyłącznie czerwone i ich średnią.



Rysunek 1: Respondenci to przechylony wycinek zaproszonych. Odpowiedzi rosną wraz ze skłonnością do udziału, więc średnia z respondentów leży znacznie powyżej średniej w populacji — a żadna waga demograficzna nie widzi osi poziomej.

Ponieważ chmura punktów jest przechylona, średnia z punktów czerwonych nie odtwarza średniej ze wszystkich punktów: średnia z respondentów wynosi 0,69 wobec prawdziwej wartości 0,14. Całym problemem jest właśnie to przechylenie. Gdyby chmura była płaska — gdyby odpowiedź nie miała nic wspólnego z chęcią udziału — średnia z respondentów byłaby nieobciążona i nic w tym tekście nie byłoby potrzebne. Dokładnie tak jest w przypadku dwóch pytań kontrolnych.

Warto zauważyć, co ważenie może tu zrobić, a czego nie. Wazenie operuje na osiach *obserwowanych* (wiek, wykształcenie, wielkość miejscowości). Przechylenie zachodzi wzdłuż osi, której nie ma w żadnym zbiorze danych. Wazenie rzetelnie naprawi każdą nierównowagę, którą widzi, i nie tknie tej jednej.

4 Projekt badania: randomizacja protokołu kontaktu

	Ramię A — kontakt standardowy	Ramię B — lekki kontakt
Zaproszenie	dzień 0	dzień 0
Przypomnienia	dni 3, 7 i 11	brak
Gratyfikacja, kwestionariusz, okno realizacji	identyczne	identyczne
Odsetek odpowiedzi (symulacja)	20,7%	5,7%
Zrealizowane wywiady (symulacja)	3 096	853
Kto się w nim znajduje	typy chętne i niechętne	wyłącznie najbardziej chętni

Ramiona różnią się dokładnie jednym: tym, jak mocno badanie naciska. Wszystko, co respondent widzi na ekranie, jest takie samo. Harmonogram przypomnień jest harmonogramem pilotażu; odsetki odpowiedzi pochodzą z demonstracji syntetycznej, w której instrument jest celowo silniejszy (zob. uwagę w następnym rozdziale).


Dwie cechy tego projektu zasługują na chwilę uwagi, bo to one czynią go tanim i wiarygodnym.

Po pierwsze, **nikt nie jest traktowany w sposób nietypowy**. Ramię A to standardowy protokół agencji. Ramię B otrzymuje *mniej* kontaktów niż standard branżowy — dlatego argumentacja etyczna jest prosta: manipulacja eksperymentalna zmniejsza obciążenie uczestników, a nie je zwiększa.

Po drugie, **manipulujemy parametrem realizacji terenowej, a nie narzędziem badawczym**. Agencje zmieniają harmonogramy przypomnień nieustannie. Nowe jest to, że robimy to celowo i losowo, oznaczamy każdy zrealizowany wywiad wskaźnikiem ramienia i analizujemy wynik. Koszt krańcowy wobec zwykłego sondażu jest bliski zeru — ramię B jest w istocie tańsze w realizacji.

5 Krok 1: czy instrument działa?

Warunek włączenia nie jest założeniem; to rzecz, którą sprawdza się w pierwszej kolejności, zanim zinterpretuje się cokolwiek innego.



Rysunek 2: Instrument działa: losowo przydzielona intensywność kontaktu zmienia odsetek odpowiedzi o 15 punktów procentowych.

W symulacji ramię standardowe daje 20,7%, a ramię lekkie 5,7% — różnica 15,1 punktu procentowego, przy statystyce z dla współczynnika przy ramieniu w równaniu pierwszego stopnia równej 38. Instrument jest silny.

! Instrument w symulacji jest celowo silniejszy niż ten, którego spodziewamy się w terenie

Różnica 15 punktów jest hojna. Realistyczne wartości dla polskich paneli internetowych to raczej 7–9% przy pojedynczym zaproszeniu i 14–17% przy trzech przypomnieniach — czyli różnica rzędu 6–8 punktów. Pilotaż jest wymiarowany pod takie liczby, a wymiarowania dokonano symulując ten właśnie projekt, a nie ze wzoru. Miękki start sprawdza przyrost jeszcze przed startem głównym, wobec progu ustawionego na **mocy testu**, a nie na poprawności instrumentu: co najmniej 7 punktów — idziemy; 5–7 — idziemy, mówiąc, ile to kosztuje; poniżej 5 — czwarte przypomnienie w ramieniu A na mocy klauzuli eskalacji w umowie. Symulacja wyolbrzymia instrument po to, by mechanizm był czytelny; nie sprawia jednak, że problem znika.

6 Krok 2: test diagnostyczny


Dla każdego pytania szacujemy regresję odpowiedzi na wskaźniku ramienia **oraz pełnym zestawie zmiennych demograficznych**, wyłącznie wśród respondentów:

$$Y_i = \alpha + \beta Z_i + X_i' \gamma + \varepsilon_i \quad (\text{Bailey, równanie 10.6})$$

gdzie $Z = 1$ dla ramienia lekkiego kontaktu. Hipoteza zerowa mówi, że $\beta = 0$: respondenci z grupy „tylko chętni” odpowiadają tak samo jak szersza pula. Jej odrzucenie jest bezpośrednim dowodem na to, że skłonność do odpowiedzi i treść odpowiedzi są ze sobą powiązane.

Czy respondenci lekkiego kontaktu odpowiadają inaczej?

Efekt ramienia B (lekki kontakt) dla każdego pytania, z kontrolą cech demograficznych · 95-proc. przedziały



Rysunek 3: Diagnostyka uruchamia się dokładnie przy czterech pytaniach skażonych z założenia i przy żadnym z pytań kontrolnych. Pytania binarne w punktach procentowych, indeksy w jednostkach odchylenia standardowego; 95-procentowe przedziały ufności.

Pytanie	Efekt ramienia B	Błąd st.	<i>p</i>	Z założenia
Pewny udział w wyborach	+7,5 pp	1,69	< 0,001	nieignorowalny
Stygmatyzowana partia	−4,0 pp	1,06	< 0,001	nieignorowalny
Indeks mniejszościowy	+0,17 SD	0,03	< 0,001	nieignorowalny
Normy demokratyczne	+0,18 SD	0,04	< 0,001	nieignorowalny
Członkostwo w UE	+1,6 pp	1,57	0,319	kontrolne (zero)
Palenie papierosów	+1,0 pp	1,60	0,521	kontrolne (zero)

Test diagnostyczny na danych syntetycznych. Respondenci lekkiego kontaktu — chętny początek kolejki — deklarują wyższą frekwencję, niższe poparcie dla stygmatyzowanej partii i bardziej progresywne postawy. Pytania kontrolne nie odbiegają od zera.

Znaki są dokładnie takie, jakich każe oczekiwać logika kolejki. W ramieniu B skupienie osób chętnych, zaangażowanych i ufnych jest większe, więc zawyża ono frekwencję nawet względem i tak już zawyżonego ramienia A, a zaniża poparcie dla partii, której zwolennicy nie ufają instytucjom.

i Dlaczego zmienne kontrolne nie są opcjonalne

Dwuzmiennowa wersja tego testu — regresja *Y* na samym *Z* — ma katastrofalny odsetek fałszywych odkryć (Bailey, rys. 11.4). Przydział do ramienia jest losowy wśród *zaproszonych*, ale nie wśród *respondentów*: warunkowanie na udziale w badaniu wytwarza korelację między ramieniem a cechami demograficznymi, a zatem i ze wszystkim, co te cechy przewidują. Dodanie *X* przywraca poprawny rozmiar testu (około 5%). To najczęstszy sposób, w jaki można zepsuć ten projekt badawczy, i właśnie dlatego zestaw zmiennych kontrolnych zostaje zamrożony w prerejestracji, a nie dobrany po fakcie.

7 Krok 3: ważenie nie ratuje pytań oznaczonych jako podejrzone

To demonstracja nośna dla całego argumentu. Wazimy próbę respondentów metodą rakingu do prawdziwych rozkładów brzegowych w populacji — płeć, grupa wieku, wykształcenie, wielkość miejscowości — czyli stosujemy

podręcznikowo doskonałą wersję tego, co robią polskie agencje, korzystając z rzeczywistych wartości populacyjnych, a nie z ich oszacowań.

Pytanie	Prawda	Sondaż	Po ważeniu	Błąd po ważeniu
Pewny udział w wyborach	49,9%	69,5%	68,9%	+19,0 pp
Stygmatyzowana partia	19,7%	10,4%	10,1%	-9,6 pp
Indeks mniejszościowy	0,14	0,69	0,64	+0,50
Normy demokratyczne	0,08	0,63	0,59	+0,51
Członkostwo w UE	76,9%	77,9%	77,2%	+0,3 pp
Palenie papierosów	21,9%	21,8%	22,0%	+0,1 pp

Konwencjonalny raking do znanych rozkładów brzegowych. Po ważeniu próba odpowiada Polsce pod względem każdej cechy demograficznej — a oszacowania dla pytań podejrzanych ledwie drgnęły.

Deklarowana frekwencja jest zawyżona o +19,6 punktu procentowego przed ważeniem i o +19,0 po nim. Poparcie dla stygmatyzowanej partii jest zaniżone o -9,3 punktu przed ważeniem i -9,6 po. Oba pytania kontrolne były trafne i takie pozostały.


Nie jest to argument przeciwko ważeniu. Ważenie zrobiło swoje: skorygowało nierównowagę demograficzną, a tam, gdzie nierównowaga demograficzna była całą historią — przy dwóch pytaniach kontrolnych — odpowiedzi są trafne. Argument brzmi tak: ważenie milczy na temat drugiego rodzaju nierównowagi, a jego milczenie łatwo wziąć za sygnał, że wszystko jest w porządku.

8 Krok 4: modele selekcji z instrumentem

Dla pytań oznaczonych jako podejrzane szacujemy model selekcji Heckmana metodą największej wiarygodności: równanie udziału w badaniu na pełnej puli zaproszonych (łącznie z tymi, którzy nigdy nie odpowiedzieli), ze wskaźnikiem ramienia jako instrumentem wyłączonym z równania wynikowego, oraz równanie wynikowe dla odpowiedzi.

Ważenie nie naprawi tego, czego nie widzi — model selekcji tak

Linia przerywana = prawdziwa wartość w populacji (znana, bo dane są syntetyczne) · pytania binarne w %, indeksy w punktach



Rysunek 4: Oszacowania surowe, ważone i skorygowane modelem selekcji wobec prawdy (linia przerywana). Model selekcji przesunął pytania podejrzane w większości drogi z powrotem; przy pytaniach kontrolnych rusza oszacowania, które ruszać nie było trzeba.

Pytanie	Prawda	Błąd surowy	Błąd po ważeniu	Błąd Heckmana
Pewny udział w wyborach	49,9%	+19,6	+19,0	−1,1
Stygmatyzowana partia	19,7%	−9,3	−9,6	+5,4
Indeks mniejszościowy	0,14	+0,55	+0,50	+0,04
Normy demokratyczne	0,08	+0,55	+0,51	+0,04
Członkostwo w UE	76,9%	+1,0	+0,3	−3,6
Palenie papierosów	21,9%	−0,1	+0,1	−2,1

Błąd każdego estymatora względem znanej prawdy, ze znakiem. Punkty procentowe dla pytań binarnych, punkty indeksu dla dwóch indeksów.

Trzy rzeczy z tej tabeli zasługują na to, by powiedzieć je wprost, zamiast prześlizgnąć się po nich.

Korekta działa tam, gdzie jest potrzebna. Przy frekwencji błąd spada z +19,6 punktu procentowego do −1,1. Przy obu indeksach maleje o mniej więcej trzy czwarte. To duże naprawy dużych obciążeń, osiągnięte bez żadnej informacji, której rzeczywisty sondaż nie mógłby mieć.

Korekta nie jest chirurgiczna. Przy poparciu dla stygmatyzowanej partii model przestrzeliwuje: prawda to 19,7%, sondaż mówi 10,4%, a wartość skorygowana wynosi 25,1% — właściwy kierunek, z grubsza właściwa skala, ale teraz błąd +5,4 punktu w drugą stronę. Oszacowanie skorygowane jest oszacowaniem lepszym, a nie dokładnym, i należy je podawać jako przedział, a nie jako liczbę. W pilotażu służą temu modele kopulowe (GJRM) szacowane obok referencyjnego modelu Heckmana, prezentacja rozrzutu między specyfikacjami oraz bootstrapowe przedziały ufności liczone na puli zaproszonych.

Przy pytaniach czystych korekta nieco szkodzi. Poparcie dla UE dryfuje o −3,6 punktu procentowego, a palenie o −2,1 — oddalając się od wartości, które raking już wcześniej ustalił poprawnie. To spodziewana cena modelu, który szacuje parametr selekcji w istocie równy zeru. To również powód, dla którego cała procedura jest **regułą decyzyjną**, a nie zastąpieniem ważenia modelowaniem selekcji.

Zastrzeżenie do wykresu

Oszacowania skorygowane na rysunku 4 przedstawiono bez przedziałów ufności, przez co wyglądają na bardziej precyzyjne, niż są w istocie; oszacowania surowe i ważne niosą wyłącznie błąd losowania, przez co z kolei one wyglądają na mniej niepewne, niż są w interesującym nas sensie. W pilotażu niepewność oszacowań skorygowanych pochodzi z bootstrapu warstwowego na puli zaproszonych, a każda kluczowa liczba jest raportowana z przedziałem. Sensem wykresu jest położenie oszacowań względem linii przerywanej, a nie ich precyzja.

9 Odczytanie wyników: drzewo decyzyjne

Produktem tej procedury nie jest jeden skorygowany zbiór danych. Jest nim odczyt — dla każdego pytania z osobna — tego, jak silnie skłonność do odpowiedzi wiąże się z treścią odpowiedzi, co dla programu badawczego jest znacznie użyteczniejsze niż korekta hurtowa. Statystyką podsumowującą jest parametr selekcji ρ — korelacja między skłonnością do odpowiedzi a treścią odpowiedzi.

Pytanie	$\hat{\rho}$	z	Werdykt	Narzędzie
Pewny udział w wyborach	0,33	4,7	nieignorowalny	model selekcji
Stygmatyzowana partia	−0,36	−4,0	nieignorowalny	model selekcji
Indeks mniejszościowy	0,28	5,1	nieignorowalny	model selekcji
Normy demokratyczne	0,29	5,1	nieignorowalny	model selekcji

Pytanie	$\hat{\rho}$	z	Werdykt	Narzędzie
Członkostwo w UE	0,08	0,9	ignorowalny	dalej ważyć
Palenie papierosów	0,05	0,6	ignorowalny	dalej ważyć


Oszacowane korelacje selekcja–odpowiedź. Oszacowania skorygowane dla pytań podejrzanych raportujemy jako przedział między specyfikacjami, a nie jako pojedyncze liczby. Tam, gdzie $\hat{\rho} \approx 0$, lepszym narzędziem jest ważenie: model selekcji dodałby szum i — jak pokazał poprzedni rozdział — odrobinę obciążenia.

Dwie rzeczy są tu łatwiejsze w symulacji niż będą w terenie. Syntetyczne badanie ma 15-punktową różnicę odsetków odpowiedzi i 4000 respondentów, więc werdykty są czyste. Pilotaż będzie miał różnicę rzędu 7–8 punktów i około 2000 respondentów, a przy takiej skali sporo pytań wróci jako nierozstrzygnięte, zamiast trafić do jednej z kolumn. Właśnie dlatego podstawowym produktem pilotażu jest oszacowanie wraz z przedziałem — $\hat{\rho}$ z przedziałem ufności, dla każdego konstruktów — a werdykty są tym, co możemy dopowiedzieć tam, gdzie prerejestrowany test okaże się rozstrzygający.

Warto też zwrócić uwagę na kierunek wnioskowania. O pytaniu mówimy, że „wykazuje nieignorowalny brak odpowiedzi”, jeżeli test ramienia z kontrolą zmiennych demograficznych prowadzi do odrzucenia hipotezy zerowej; $\hat{\rho}$ pełni rolę potwierdzającą. Test jest pierwszy, ponieważ jest nieparametryczny i ma poprawny rozmiar, podczas gdy heckmanowskie oszacowania ρ odrzucają zbyt często przy błędnej specyfikacji. Twierdzenie o *ignorowalności* formułujemy zaś afirmatywnie, za pomocą testu równoważności (TOST wobec najmniejszego istotnego efektu $\pm 0,10$ SD, również dla pytań binarnych), nigdy zaś przez brak istotności. „Nie wykryliśmy problemu” i „możemy zaświadczyć, że nie ma problemu istotnej wielkości” to dwa różne stwierdzenia — i tylko drugie jest cokolwiek warte dla programu badawczego.

10 Co to oznacza dla polaryzacji

Jeden z wyników amerykańskiego zastosowania metody przez Baileya wart jest odtworzenia, bo zmienia sposób czytania znanego nagłówka.



Rysunek 5: Sondaże wyolbrzymiają polaryzację: obserwowana różnica sympatii do własnej i przeciwnej partii wśród zwolenników partii wynosi 50,3 punktu wobec prawdziwej różnicy 39,1.

Zaangażowani zwolennicy partii chętniej biorą udział w badaniach i są bardziej niechętni drugiej stronie. Oba obozy są więc reprezentowane w danych przez swoich bardziej bojowych przedstawicieli, a dzieląca je różnica zostaje zawyżona — tutaj o 11,2 punktu na skali stupunktowej, przy czym raking usuwa z tego niemal nic (49,7 po ważeniu), a model selekcji odtwarza 37,7.

Szersza lekcja dotyczy tego, co to obciążenie robi z porównaniami **wewnątrz podgrup**. Wielkość może być nieobciążona w całej próbie, a jednocześnie mocno obciążona w każdej z porównywanych grup, jeśli obciążenia biegną w przeciwnych kierunkach i przypadkiem się znoszą. Bailey znalazł dokładnie to przy poparciu dla Trumpa: zagregowana wartość wyglądała poprawnie, podczas gdy odpowiadający Demokraci byli bardziej antytrumpowscy niż typowi Demokraci,

a odpowiadający Republikanie bardziej protrupowscy niż typowi Republikanie. Każda analiza sięgająca *wewnątrz* elektoratów partyjnych — czyli większość tego, co politolodzy robią z danymi sondażowymi — dziedziczy problem, który liczby zagregowane skrywają.

11 Od demonstracji do pilotażu FRBN

11.1 Co faktycznie zrealizujemy

Finansowanie	Fundusz Rozwoju Badań Naukowych Uniwersytetu SWPS, decyzja nr 67/2026/FRBN/C; 21 000 zł netto, wyłącznie realizacja terenowa
Zespół	Ben Stanley (kierownik), Mikołaj Cześnik, Marta Żerkowska-Balas
Projekt badania	Jedno ogólnopolskie badanie CAWI, ok. 10–12 minut, w panelu internetowym; pula ok. 18 500 osób wylosowana z góry i podzielona losowo w proporcji 42/58 na ramię A (zaproszenie i trzy przypomnienia, dni 0/3/7/11) oraz ramię B (jedno zaproszenie, nic więcej). Proporcja jest nierówna, bo ramię B wymaga mniej więcej dwukrotnie większej liczby zaproszeń, by dać tyle samo wywiadów, a szacowaną wielkością jest różnica między ramionami
Cel realizacyjny	ok. 2000 zrealizowanych wywiadów (ok. 1200 w ramieniu A, ok. 800 w B), każdy oznaczony ramieniem i falą przypomnienia
Okno realizacji	14 dni, koniec października – początek listopada 2026, zamknięcie przed 11 listopada
Kwestionariusz	Brzmienia pytań z PGSW/CSES/EVS: zaangażowanie, frekwencja i głosowanie (w tym deklaracje retrospektywne: Sejm 2023 i prezydenckie 2025), termometry sympatii do partii i liderów, postawy wobec mniejszości, normy demokratyczne oraz pytania kontrolne i zachowania z punktem odniesienia
Prerejestracja	Hipotezy, plan analizy, reguły decyzyjne i procedury awaryjne zamrożone na OSF przed startem badania głównego
Etyka	Komisja ds. Etyki Badań Naukowych Uniwersytetu SWPS; ramię lekkie zmniejsza obciążenie kontaktowe wobec standardu branżowego

Pilotaż w jednej tabeli. Budżet pokrywa wyłącznie realizację terenową; projekt badania, analiza i raportowanie wykonywane są własnymi siłami.

11.2 Co rzeczywiste badanie ma, a czego symulacja nie miała

Zewnętrzne punkty odniesienia. Symulacja mogła sprawdzić swoje odpowiedzi wobec znanej prawdy. Pilotaż konfrontuje część pytań z danymi urzędowymi: deklarowaną frekwencję i głosowanie w wyborach do Sejmu 2023 oraz w wyborach prezydenckich 2025 z wynikami PKW; palenie papierosów z GUS/EHIS; posiadanie prawa jazdy z danych CEPiK; praktyki religijne z CBOS/ISKK. Wartości te potwierdzają kierunek i rząd wielkości, a nie dokładność co do miejsca po przecinku — błąd pamięci jest realny — ale korekta, która przesuwająca deklarowaną frekwencję w stronę danych PKW, robi coś widocznego i sprawdzalnego.

Pięciostopniowy gradient skłonności bez dodatkowych kosztów. Wewnątrz ramienia A fala przypomnienia, po której dana osoba wypełniła ankietę (0, 1, 2, 3), jest stopniowalną, wynikającą z protokołu miarą niechęci. W połączeniu z ramieniem B daje to pięć uporządkowanych poziomów skłonności zamiast dwóch, co pozwala testować trend i zabezpiecza przed niemonotonicznością — jednym ze znanych sposobów, w jakie ten projekt może zawieść. Daje też

czysty test placebo: respondenci z ramienia B i respondenci z fali 0 w ramieniu A otrzymali w momencie wypełniania identyczny bodziec, więc jakakolwiek różnica między nimi sygnalizowałaby usterkę instrumentu.

Projekt zwymiarowany symulacją, a nie wzorem. Całą analizę zbudowaliśmy i uruchomiliśmy na danych syntetycznych, zanim pojawiły się dane rzeczywiste — i stąd właśnie wzięły się trzy przypomnienia w protokole kontaktu zamiast dwóch. Przy dwóch symulowana różnica odsetków odpowiedzi wynosiła około 5 punktów, a przy takiej różnicy testy confirmacyjne wykrywały spodziewane efekty mniej więcej raz na dziesięć prób: różnica między ramionami zależy od tego, jak bardzo różni się ich skład, a 5 punktów zmienia ten skład bardzo nieznacznie. Zwiększanie próby nie jest tu lekarstwem — moc rośnie z pierwiastkiem z n , a budżet jest stały; różnicę odsetków kontroluje natomiast sam protokół. To samo ćwiczenie przebudowało projekt części confirmacyjnej: cztery konstrukty zamiast trzynastu pytań, testy jednostronne w prerejestrowanym kierunku i łączny test dla całej rodziny hipotez jako główne twierdzenie. Razem zmiany te przesuwają pilotaż z wykrywania poszukiwanych efektów mniej więcej raz na dziesięć prób do mniej więcej dwóch razy na trzy, przy teście łącznym bliskim pewności. Dwie trzecie to wciąż mniej, niż chciałoby się mieć w badaniu rozstrzygającym — i dlatego pilotaż raportuje oszacowania z przedziałami, a nie werdykty.

Uczciwe ograniczenia. Symulacja ma 15-punktową różnicę odsetków odpowiedzi, poprawnie wyspecyfikowane rozkłady składników losowych i znaną populację. Pilotaż będzie miał różnicę mniejszą, możliwą błędną specyfikację modelu i co najwyżej przybliżone punkty odniesienia. Właśnie dlatego podstawowe wnioskowanie opiera się na nieparametrycznym teście ramienia, a nie na modelach; dlatego modele kopulowe wyznaczają przedział wokół oszacowania Heckmana, zamiast je rozstrzygać; i dlatego w materiale uzupełniającym znajdują się granice Manskiego oraz analizy wrażliwości.

11.3 Główne ryzyka i to, co je amortyzuje

Ryzyko	Sposób ograniczenia
Zbyt mały przyrost z przypomnień — słaby instrument	Przyrost realizacji fala po fali jest wymaganiem obowiązkowym w zapytaniu ofertowym; miękki start z progiem ustawionym na mocy testu, a nie na poprawności instrumentu; czwarte przypomnienie w ramieniu A bez dodatkowego wynagrodzenia na mocy klauzuli eskalacji; test gradientowy pozostaje informacyjny
Agencja nie potrafi realizować badania na zaproszenia albo oznaczać ramion	Kryterium dopuszczające w zapytaniu ofertowym; rekrutacja routerowa i linki otwarte dyskwalifikują ofertę, bo bez ustalonej puli zaproszonych nie ma mianownika ani kontrolowanego protokołu
Brak danych jednostkowych o nierespondentach (RODO)	Zbiorcze tabele krzyżowe puli zaproszonych wymagane umownie; metoda pseudonierespondentów odtwarza rozkład ich cech z rozkładów brzegowych
Niestabilność modeli selekcji przy części pytań	Podstawowe wnioskowanie nigdy od nich nie zależy; diagnostyka współliniowości raportowana rutynowo; brak zbieżności dokumentowany, a nie ukrywany
Realizacja zbiega się ze wstrząsem politycznym	Krótkie okno; znaczniki czasu wypełnienia; efekty stałe dnia realizacji jako test odporności; placebo z falą 0
Podjęcie o swobodę decyzyjną badacza	Zamrożona prerejestracja, korekta Benjaminiego-Hochberga w rodzinie hipotez confirmacyjnych, afirmatywne testy równoważności dla twierdzeń o braku efektu oraz pełne udostępnienie kodu i danych

Rejestr ryzyk (skrótowy, za dokumentem projektowym).

11.4 Co z tego powstanie

1. **Raport metodologiczny po polsku** dla SWPS i FRBN, wraz ze streszczeniem napisanym dla dziennikarzy pracujących z sondażami: dla każdego pytania — jak silnie skłonność do odpowiedzi wiąże się z jej treścią, wraz z uczciwym przedziałem; które pytania potrafimy wskazać jako zniekształcone; i czego ważenie naprawić nie potrafi.
2. **Manuskrypt artykułu po angielsku**, kierowany do *Public Opinion Quarterly*, a następnie do *Survey Research Methods* lub *IJPOR*. Atutami są: pierwsze systematyczne zastosowanie randomizowanego instrumentu odpowiedzi

w panelu z Europy Środkowo-Wschodniej, walidacja wobec zewnętrznych punktów odniesienia oraz dowody na „lustrzane” obciążenia partyjne poza amerykańskim kontekstem dwupartyjnym.

3. **Publiczne repozytorium:** projekt R z zamrożonym `renv`, potok `targets`, pakiet symulacyjny, na którym oparty jest ten tekst, zanonimizowane dane, kwestionariusz po polsku i angielsku, wzór załącznika do umowy z agencją oraz krok po kroku opisany przewodnik wdrożeniowy („jak dodać ramię lekkiego kontaktu do własnego badania CAWI”).
4. **Warsztat** dla zespołu PGSW i pracowników CSD, z konkretną propozycją ramienia lekkiego kontaktu w kolejnej kompetencji CAWI PGSW i modelem kosztowym z tego pilotażu.
5. **Dźwignia grantowa:** oszacowania wielkości efektów i sprawdzony protokół pod wniosek NCN OPUS w pełnej skali oraz argument pozycjonujący CSD w konkursach infrastrukturalnych Horyzontu Europa.

11.5 Po co to wszystko, w jednym akapicie

Zamiast zakładać, że osoby ignorujące nasze sondaże myślą tak samo jak te, które na nie odpowiadają, przeprowadzamy wewnątrz badania mały eksperyment z randomizacją, który mierzy — pytanie po pytaniu — na ile to założenie się trzyma, i naprawia liczby tam, gdzie się nie trzyma. Diagnostyka kosztuje niemal nic, bo losuje parametr realizacji terenowej, którym agencje i tak manipulują. Produktem nie jest skorygowany zbiór danych. Są nim oszacowania: dla każdego konstruktów — jak silnie skłonność do udziału wiąże się z treścią odpowiedzi, wraz z przedziałem; wskazanie tych pytań, przy których związek ten jest na tyle wyraźny, że da się go wykazać; protokół, który inne polskie badania mogą do siebie dołączyć; oraz wielkości efektów potrzebne do tego, by badanie w pełnej skali miało odpowiednią moc. Pilotaż na 2000 respondentach nie rozstrzygnie wszystkich pytań, które stawia — jak pokazuje symulacja, część wróci jako nierozstrzygnięte — ale powie, jak duży jest problem i czego wymagałoby jego porządne zmierzenie.

12 Bibliografia

Bailey, M. A. (2024). *Polling at a Crossroads: Rethinking Modern Survey Research*. Cambridge University Press. (rozdz. 5–12)

Heckman, J. J. (1979). Sample selection bias as a specification error. *Econometrica*, 47(1), 153–161.

Meng, X.-L. (2018). Statistical paradises and paradoxes in big data (I): law of large populations, big data paradox, and the 2016 US presidential election. *Annals of Applied Statistics*, 12(2), 685–726.

Peress, M. (2010). Correcting for survey nonresponse using variable response propensity. *Journal of the American Statistical Association*, 105(492), 1418–1430.

Sun, B., Liu, L., Miao, W., Wirth, K., Robins, J., & Tchetgen Tchetgen, E. J. (2018). Semiparametric estimation with data missing not at random using an instrumental variable. *Statistica Sinica*, 28, 1965–1983.

Projekt finansowany ze środków Funduszu Rozwoju Badań Naukowych Uniwersytetu SWPS (decyzja nr 67/2026/FRBN/C).